引用体检 · 技术说明

从参考文献事实，到正文论断证据。一套面向论文写作自查、保留来源和不确定性的 AI Web 工作流。

> **产品主张：每一个判断，都应能回到数据库记录或原文片段。**

项目摘要

参考文献的书目真实性与正文论断的证据支持是两个问题。本项目把它们分为独立工作区：前者用公开学术数据库逐字段核对题名、作者、年份、期刊与 DOI；后者先检索证据片段，再由 DeepSeek 判断一条论断与材料的关系。

在规则核验之外加入了五项 AI 能力：受约束的字段解析、对查不到条目的 AI 检索 Agent、拍照 / 截图识别参考文献、读取开放全文并混合检索的论断 RAG，以及把核验工具开放给其他 AI 的 MCP Server。导入文档时还会检查读者看不见、AI 却会读到的隐藏提示词。模型输出都经过结构与原文校验，真伪结论由规则或带原文引句的判断给出。

项目项	当前信息
参赛方向	第九届传智杯 • AI WEB 网页开发挑战赛
运行形态	Next.js 16 Web 应用 + stdio MCP Server；本地生产预览；未声明公网部署
AI 提供方	DeepSeek（deepseek-flash）：函数调用、多轮工具调用、图片输入
材料日期	2026-10-17；本地技术验收版
代码仓库	GitHub 私有仓库，保留真实提交历史；正式提交前公开或授权评审访问
学校、队伍与成员	待本人补充真实身份及分工；本材料不编造团队信息

文档范围：项目概述、需求分析、架构、AI 技术、核心实现、测试与部署、创新和展望。本文不构成官方成绩、临床或学术结论认证。

01 需求与问题边界

目标用户是需要复核 AI 辅助写作引用的学生、研究者与写作辅导人员。当前尚无真实用户访谈或使用效果研究，因此这里是产品需求假设与已实现任务范围。

用户要解决的问题	产品行为	不能据此推出
引用是否真实、字段有无写错	数据库核验与逐字段差异	查不到就一定是编造
查不到的条目还能不能找到	AI 检索 Agent 多轮检索，规则确认候选	Agent 没找到就是编造
纸质论文、扫描件里的参考文献	拍照 / 截图识别，对照原图确认后再核验	识别结果不必核对
引用是否支持正文一句话	读取开放全文、检索片段、关系判断、原文引句	存在文献就支持论断
论文里藏着写给 AI 的指令	导入时检测隐藏文字，列出并移除	没有检出就一定没有

两个任务，各自保留判断依据

参考文献体检回答元数据问题：记录是否可查、是否同一篇、字段哪里不同、是否存在撤稿或关注标记。规范写法依据已取得的数据库元数据生成，不让模型编写文献信息。

论断证据核查回答有限材料中的关系问题：支持、部分支持、矛盾或证据不足。它不是事实搜索引擎；DOI 只能读到开放获取全文（Europe PMC、arXiv），其余只有摘要。用户文本仅标为用户提供，系统不认证其真实性。

验收标准

正常输入要能形成可复核结果；错误、缺配置、取消与证据缺失要有不同状态；导入和识别的文字在应用前可检查；对外展示的功能、测试数字与实际文件一致。性能、准确率与市场价值没有测量依据时不作量化承诺。

02 系统架构与数据流

前端采用 Next.js App Router、React、TypeScript 和 Tailwind CSS。服务端模块把文件提取、规则核验与模型调用隔开，模型密钥不进入客户端。



边界	实现职责
页面与组件	输入、来源范围、进度、取消、结果与报告；手机布局
/api/check • /api/agent	流式参考文献核验；单条 AI 检索的逐步结果
/api/import • /api/vision	文件提取与隐藏文字检测；图片识别参考文献
/api/claims	证据获取、混合检索、模型判断与引用校验
pnpm mcp（stdio）	verify_references、check_claim 两个工具开放给 MCP 客户端
lib/verify • agent • claims • documents • vision	业务逻辑与 UI 解耦；模块测试覆盖各自边界

信任边界

公开数据库响应、用户文件、图片和模型输出都视为外部输入。数据库结果不等于真实世界全部知识；上传文字不等于可信论文；模型文本也不直接成为程序事实。每条链路在输入、来源、结构和输出位置上设置校验。

03 参考文献：工具调用与事实核验

选用 DeepSeek 复用现有配置与中文交互能力，采用受约束的 Function Calling。当前没有与其他模型做质量或成本对照实验，因此不声称它是最优模型。

集成方式

标准模式由规则提取条目和字段；AI 模式在数据库查询前加入 verify_references 工具调用。服务端预先固定条目边界，只接受原文可支持的字段。模型不能增删条目、改写原文、覆盖已有错误证据或调用任意工具。

有 DOI 时先取元数据；必要时核对 DOI 注册与内容协商结果。整条引文通过 Crossref 模糊检索，英文条目必要时使用 OpenAlex 兜底。匹配与结论由程序依据取得的数据执行。

关键保护	用户可见结果
作者、年份、期刊依据保留	模型不能把原文中的错误提前修掉
同篇判定独立于相近候选	只有相近候选时单列，不算信息有误，保留原文
撤稿与关注声明分开	不同的学术状态不会被合并成同一标签
连接失败与查无记录分开	故障和预算不足记为未完成，不当作不存在
覆盖范围先核对	期刊在引文年份未被 Crossref 收录时，查不到不算证据
汉字作者与拼音记录	跨文字比对作者，不把写法差异判为作者错误

用真实论文的参考文献调规则

评测集从 Crossref 按出版社随机抽取 2023 年后发表的论文，再从其参考文献中随机取原文，每一条都真实存在。dev 108 条用于调规则；test 119 条在规则定稿前不看、只跑一次。2026-10-15 的修复把 test 误报从 16.0% 降到 10.1%（逐条复核）。

10-16 逐条分析剩下的 12 条误报，修了 9 类规则（题名缩写、会议报告与机构报告、复姓缩写、汉字与拼音、期刊收录年份等）。修后 test 不再算盲测，另抽了 110 条来自 64 篇不同论文的新盲测集，只运行一次：逐条复核误报 10 条（9.1%）。按其中五类误报（非期刊文献配错记录、软件、题名边界、网页、数据库差异）再修后，又抽 111 条第三批盲测集，误报 13 条（11.7%）。三次盲测在同一水平，新数据上的误报换成了新的格式和数据源问题。第三批的 13 条里有 6 条只找到相近候选，现已单列为“相近候选”；上面的数字按原口径计（相近候选也算误报），新口径还没有在新数据上检验。

04 AI 检索 Agent：模型规划检索，规则判定结论

对“无法核验 / 只找到相近候选”的条目，用户可点“AI 继续查”。DeepSeek 阅读原文、已解析字段和已经查过的路径，自己决定下一步调用哪个工具，每一步实时显示在卡片上。



约束	做法
工具白名单	search_crossref、search_openalex（每条最多 1 次）、search_datacite、lookup_doi、finish
参数校验	工具名、字段、长度、年份范围、DOI 格式；DOI 只能查引文或检索结果中出现过的
不能下结论	模型不能指定哪一篇算数，不能制造“疑似不存在”；含真伪判断词的小结不显示
预算与失败	每条最多 4 次检索、4 轮模型调用、80 秒；失败或超时保持原结论并如实说明

评测与复核

dev 61 条可追查：确认 3 条，均为已核实。test 58 条是 Agent 的盲测：确认 7 条（4 条已核实、3 条信息有误），没有失败，也没有变成“疑似不存在”；每条平均约 3 次检索、5.5 – 5.8 千 token、10 – 12 秒。

盲测 7 条逐条复核：1 条匹配到同一作者的新文章，1 条是报告的旧版本，据此补了两条保守规则。52 条中文条目 Agent 一条也没找到——知网、万方没有开放接口，这是数据源的限制，不是模型能弥补的。

05 论断：开放全文、混合检索与带引句判断

论断接口每次接收一条论断，使用 DOI 或用户文本中的一种。DOI 优先读取开放获取全文，只访问固定的白名单数据源，不接受模型或用户指定的任意地址。



证据来源

依次尝试 Europe PMC 开放全文（JATS XML，去掉参考文献、表格内容和公式）、arXiv 预印本 PDF（DOI 本身是 arXiv，或出版社在 Crossref 登记了预印本；PDF 走导入的安全解析器，并排除隐藏文字），都没有才用 Crossref / OpenAlex 摘要。只访问 www.ebi.ac.uk 与 export.arxiv.org，不跟随跳转，XML 最多 6 MiB，PDF 最多 8 MiB。

混合检索

多于 6 段时，原论断的 BM25（英文按词、中文按相邻两字）与模型扩展检索词（中英文同义词、缩写）的 BM25 按倒数排名融合取 20 段，再由模型按 0–3 分重排，取前 6 段交给判断。两步输出逐项校验：检索词不能含网址，重排只能用候选片段的编号；失败时退回词面检索并在结果中说明。DeepSeek 没有向量接口，所以没有做向量检索。

输出约束

judge_claim 输出结论、解释与引句；服务端核对片段编号与逐字引句，返回规范化文本中的字符区间。引句可定位不保证解释正确；该流程不独立核验撤稿状态。

06 论断检索评测

三篇 CC BY 开放获取论文（Walters & Wilder 2023、Kung 等 2023、Bhattacharyya 等 2023），评测时经 Europe PMC 实时获取全文，与产品同一条路径。24 条原文支持的论断：每篇 4 条英文转述、4 条中文表述，用词刻意与原文不同，并标注出处句子。

检索方式	前 6 段命中率	MRR	中文 12 条命中率
词面 BM25（升级前）	75%	0.61	50%
+ 模型扩展中英文检索词	100%	0.79	100%
+ 模型重排（现在的默认）	100%	0.98	100%

解读

24 条的出处句子只有 2 条在摘要里：只读摘要，大多数论断找不到证据，读取开放全文是必要的。中文论断对英文原文时，词面检索只找到一半；查询扩展补上了跨语言的部分，重排把出处片段排到第 1 位（23/24）。

局限

样本小；论断由评测者通读全文后编写，而且都是原文支持的说法。三篇论文都不长（14–31 段），重排的 20 段候选覆盖了文档的大部分，长文档上的提升可能更小。这里只评检索，没有评判断准确率。

一次真实页面核查

生产构建中输入中文论断“即使用 GPT-4，它引用的书籍章节里也有七成是编造的”和 DOI 10.1038/s41598-023-41032-5：结果为“证据支持”，引句来自论文 Results 一节的原文，判断范围标为 Europe PMC 开放全文，并列出检索方式与扩展检索词。这句话在摘要里没有。

07 多模态：拍照 / 截图识别参考文献

扫描版 PDF 没有文字层、纸质论文只能拍照时，用户上传 1–4 张图片或在参考文献框里直接粘贴截图，由 DeepSeek 视觉模型逐条转写。



设计	说明
只转写，不判断	不改错、不补全、不翻译；真伪由后续的数据库核验给出
图片里的文字是数据	不执行图片中的指令；模型只能调用 submit_references
输出校验	只接受 entries 字段；最多 80 条、每条 2,000 字符；去掉控制字符
隐私与限额	原图只在请求内存中使用；每 IP 每分钟 4 次、每进程每小时 40 次、同时 2 个

评测

用 16 条真实文献生成英文截图、中文截图，以及加了纸张底色、倾斜、模糊、噪点和 JPEG 压缩的中英混排“手机照片”：16/16 逐字一致，字符错误率 0%，每张 3–5 秒。识别结果和标准答案分别送去核验，结论完全一致。

这是印刷体合成样本，只说明链路可用、转写不会改变结论；真实拍照的反光、透视和手写批注没有覆盖，所以界面要求对照原图逐条核对。

08 文档导入与隐藏提示词检测

导入模块只提取可读文本：PDF.js 读取 PDF 文字层，yauzl 与 saxes 解析 DOCX；文字预览确认后才填入。扫描件没有文字层时，引导用户截图走图片识别。

为什么要查隐藏文字

2025 年 7 月，日经亚洲报道 17 篇 arXiv 预印本用白字或极小字号藏了“只给正面评价”之类写给 AI 审稿工具的指令（Sugiyama & Eguchi, 2025）；Lin 的评论文章统计到 18 篇（arXiv:2507.06185）。本项目会把论文交给 AI 解析和论断核查，导入时必须先查一遍。

格式	检测内容
PDF	白色或接近白色的填充（灰度、RGB、CMYK）、不可见渲染模式、小于 1.5 磅、画在页面外
DOCX	隐藏格式（含样式继承）、浅色底上的白字、小于 2 磅
所有格式	Unicode 标签字符（把 ASCII 指令编码成看不见的字符）与零宽字符

实现与误报控制

PDF.js 的文字条目不带颜色，取绘图指令又会解码图片（被本项目的解码器防护拦截），因此在已校验哈希的 worker 后追加只读钩子，在提取文字的同一遍里跟踪填充色和渲染模式，不改变提取结果。

像写给 AI 的指令一律列出并从导入文字中去掉；不像指令的，白字短于 40 字、其他方式短于 12 字的按正常排版保留，扫描件的 OCR 文字层只提示。自家 11 页技术说明 PDF 的 24 处深色表头白字没有一处被误报。

资源边界：文件 8 MiB、PDF 100 页、文字 160,000 字符；PDF 单解码缓冲 8 MiB、每文档累计 32 MiB；DOCX 限制条目、展开体积与压缩比，拒绝宏、XML 实体和不安全路径。被图片盖住、透明、裁剪或批注里的文字不在检测范围内。

09 MCP Server、可控性与隐私

pnpm mcp 以 stdio 启动 MCP Server（官方 TypeScript SDK 1.31.0），把两个只读工具开放给 Claude、Cursor 等 MCP 客户端，结论与网页端同源。

工具	输入	输出
verify_references	参考文献列表（最多 80 条 / 60,000 字符）	每条结论、问题、匹配记录与规范写法；逐条发送进度通知
check_claim	论断，加 doi 或 evidence_text	四类关系与逐字核对过的原文引句

场景	处理策略
标准文献核查	只向公开数据库查询引文，不请求语言模型
AI 解析 / AI 检索	向 DeepSeek 发送对应条目；检索工具只访问固定的学术数据源
图片识别	图片发给 DeepSeek；上传前重新编码、去掉 EXIF；原图不保存
论断核查	发送论断、最多 20 段候选和 6 段证据，不是整个文件
密钥与提示注入	密钥只在服务端；材料与图片中的指令一律当数据；未知工具、非法字段一律拒绝
失败、中止或无证据	状态区分；失败不会被替换成支持、矛盾或真实性结论

限额以 Node 进程为边界，重启会清零，多实例不共享；公网服务需可信代理、共享限流、账户与费用观测。目前未完成完整负载或渗透测试。

10 验证方法与实测结果

以下记录区分离线固定响应、真实网络与浏览器操作。测试通过只覆盖列出的样本和版本，不推导真实世界总体准确率。

层级	实测记录	解释范围
自动测试	36 个文件 509 项；lint、类型检查、生产构建通过	固定上游响应，覆盖边界与回归
自建文献样例	29/29；编造 7/7；真实文献误判“不存在” 0/15	真实联网，自建小样本
真实论文参考文献	test 119 条盲测：误报 16.0% → 10.1%（逐条复核）	10-15 盲测一次
10-16 两轮修复	test 误报 12 → 0、第二批盲测 10 → 0；dev 仍为 0，3 条真实错误仍被标出	修过的集合不再算盲测
第二批盲测	110 条：误报 10 条（9.1%，逐条复核），其中疑似不存在 2 条；另有 1 条无法确认	10-16 盲测一次，64 篇论文
第三批盲测	111 条：误报 13 条（11.7%，逐条复核），其中疑似不存在 4 条	10-16 晚盲测一次，62 篇论文
AI 检索 Agent	test 58 条：确认 7 条，没有失败，也没有判为疑似不存在	Agent 的首次盲测
图片识别	16/16 逐字一致，字符错误率 0%	合成印刷体样本
论断检索	前 6 段命中率 75% → 100%，MRR 0.61 → 0.98	24 条，评测者编写
隐藏提示词	夹具中 PDF 6 处、DOCX 4 处、TXT 1 处全部检出；自家 PDF 无误报	合成夹具 + 真实 PDF
MCP 与真实模型	两个工具真实调用通过；论断冒烟 4/4	流程可用，不是准确率

评测限制

自建样本量小且有选样偏差；合成材料只检查行为，不是真实研究结果。没有跨领域大样本的判断准确率、标注一致性、用户效率或商业转化研究。两批新盲测集各约 110 条，误报率的 95% 区间约为 5%–19%，复核由开发方完成，没有独立标注；中文条目多数无法核验。盲测误报都按原口径计，“相近候选”也算在内；不计相近候选的新口径还没有在新抽的盲测集上运行。

11 运行、配置与复现

当前交付为本地源码与验收材料，不等于已完成公网部署或正式赛事提交。评审应使用自己的服务端密钥，复现时保留时间、输入、模型名称与结果。

步骤	执行或配置
环境	Node.js 22.13+；pnpm；以 package.json 和 pnpm-lock.yaml 为准
安装	pnpm install；复制 .env.example 为 .env.local，已有配置不覆盖
AI 配置	DEEPSEEK_API_KEY；可选 DEEPSEEK_MODEL、DEEPSEEK_BASE_URL
数据库配置	建议设置 CROSSREF_MAILTO、OPENALEX_API_KEY；只保留在服务端
开发 / 生产	pnpm dev；pnpm build 后 pnpm start --port 3210
MCP Server	pnpm --silent --dir <项目目录> mcp（stdio）
质量检查	pnpm test；pnpm lint；pnpm typecheck；pnpm build
联网评测	pnpm eval:real、eval:agent、eval:vision、eval:retrieval；pnpm sample:real 抽新盲测集

复现注意

没有 AI 密钥时仍可使用标准文献核验；AI 解析、Agent、图片识别和论断判断需要模型配置。公开数据库和模型会变化，复现记录应保存时间、输入、配置的模型名称与结果，不保存密钥。OpenAlex 无 key 时额度很少，连续全量评测会触发 Crossref 限流，评测需分开运行。

自动测试中的固定上游响应保证可重复性，但不能证明当天外部服务可用；真实联网测试会产生少量模型费用，也不能代替离线边界测试。

公网演示是官方可选加分项。本轮没有对外发布授权，不把本地端口写成可公网访问链接；正式提交前另行验证评审访问。

12 创新点、局限与发展方向

创新定位是应用与工程组合：把 AI 引用问题拆成可追溯的事实核验和证据核查，而不是声称新的基础模型或检索算法。

层面	当前设计价值	尚缺证据
应用	文献事实与正文证据分开；从格式走向可复核判断	真实用户规模和效率改善
技术	Agent 只找证据、规则下结论；开放全文 + 跨语言混合检索；隐藏提示词检测	跨模型比较与长文档检索消融
交互	保留错误原文、来源范围、失败状态与 Agent 的检索理由	系统可用性研究与无障碍完整评估
社会价值	帮写作者发现引用问题，识别写给 AI 的隐藏指令	真实教学或学术场景的效果研究
商业	图书馆、写作中心、期刊投稿前检查	付费意愿、单位成本、转化及留存

已经明确的局限

开放数据库覆盖不完整，知网、万方没有开放接口，中文条目 Agent 也找不到；中文题名对英文元数据仍无法比对。开放全文只覆盖 Europe PMC 开放获取子集和 arXiv，预印本可能与正式版本不同。图片识别只转写参考文献，未覆盖手写、强反光和严重透视。隐藏文字检测不覆盖被图片盖住、透明、裁剪或批注里的文字。没有账户、计费与公网运营。

下一阶段优先级

三次盲测的误报都在 9% – 12%，逐类补规则在新数据上收益有限。只找到相近候选的条目已单列，不再算信息有误；下一步把英文转写的中文期刊、未写编号的预印本这类数据源缺口改判为无法核验，请第二人独立标注，并另抽新盲测集检验新口径；在长文档上做检索消融；找真实写作者试用，测量复核时间与误报成本；再决定公网部署、远程 MCP 与机构试点是否值得投入。

13 证据索引与提交对应

本地路径以下按项目根目录 D:/Darks/projects/cite-checkup 表示。复核时先查看最终状态文件，再核对实际文件，避免把旧版本验收当成新版本。

证据	项目内位置 / 说明
最终项目状态	PROJECT_STATE.md；作为索引，关键结果需核对实际文件
真实论文参考文献	eval/real-world/（dev、test、blind-2026-10-16、blind-2026-10-16b）；eval/results/real-*-2026-10-15-*.json、real-*-2026-10-16*.json（含盲测复核与逐条对比）
自建文献回归	eval/results/curated-2026-10-16-v2.json
AI 检索 Agent	eval/results/agent-dev-2026-10-15.json、agent-test-2026-10-15.json
图片识别	eval/vision/cases.json；eval/results/vision-2026-10-16.json
论断检索	eval/claims-retrieval/cases.json；eval/results/retrieval-2026-10-16.json
隐藏提示词	src/lib/documents/__tests__/fixtures/generate_hidden.py 及生成的夹具
MCP 实连	eval/results/mcp-smoke-2026-10-16T00-35-59-125Z.json
讲稿与内容源	docs/competition/ 下 narration.json、DEMO_SCRIPT.md、DEFENSE_QA.md、technical-content.json

官方材料要求对应

官方要求技术 PDF 不超过 30 页，包含概述、需求、架构、AI、实现、测试部署和展望。本报告共 14 页，对应这些部分；AI 选型、集成、优化和创新均单独说明。

正式视频须为 5－8 分钟、MP4、至少 1080p、普通话讲解。代码仓库需可供评审访问、保留真实历史并补齐团队资料。本轮不代为报名、公开仓库或提交赛事。官方页面核对日期为 2026-10-14。

官方来源：https://www.boxuegu.com/matchTrack/detail/?id=10037

参考：Sugiyama, S., & Eguchi, R. (2025). Nikkei Asia. https://asia.nikkei.com/Business/Technology/Artificial-intelligence/Positive-review-only-Researchers-hide-AI-prompts-in-papers

参考：Lin, Z. (2025). Hidden Prompts in Manuscripts Exploit AI-Assisted Peer Review. https://doi.org/10.48550/arXiv.2507.06185