# 引用体检 · 技术说明

从参考文献事实，到正文论断证据。一套面向论文写作自查、保留来源和不确定性的 AI Web 工作流。

> **产品主张：每一个判断，都应能回到数据库记录或原文片段。**

## 项目摘要

参考文献的书目真实性与正文论断的证据支持是两个问题。本项目把它们分为独立工作区：前者用公开学术数据库逐字段核对题名、作者、年份、期刊与 DOI；后者先检索证据片段，再由 DeepSeek 判断一条论断与材料的关系。

在规则核验之外加入了五项 AI 能力：受约束的字段解析、对查不到条目的 AI 检索 Agent、拍照 / 截图识别参考文献、读取开放全文并混合检索的论断 RAG，以及把核验工具开放给其他 AI 的 MCP Server。导入文档时还会检查读者看不见、AI 却会读到的隐藏提示词。模型输出都经过结构与原文校验，真伪结论由规则或带原文引句的判断给出。

| 项目项 | 当前信息 |
| --- | --- |
| 参赛方向 | 第九届传智杯 • AI WEB 网页开发挑战赛 |
| 运行形态 | Next.js 16 Web 应用 + stdio MCP Server；本地生产预览；未声明公网部署 |
| AI 提供方 | DeepSeek（deepseek-flash）：函数调用、多轮工具调用、图片输入 |
| 材料日期 | 2026-10-16；本地技术验收版 |
| 代码仓库 | GitHub 私有仓库，保留真实提交历史；正式提交前公开或授权评审访问 |
| 学校、队伍与成员 | 待本人补充真实身份及分工；本材料不编造团队信息 |

文档范围：项目概述、需求分析、架构、AI 技术、核心实现、测试与部署、创新和展望。本文不构成官方成绩、临床或学术结论认证。

# 01 需求与问题边界

目标用户是需要复核 AI 辅助写作引用的学生、研究者与写作辅导人员。当前尚无真实用户访谈或使用效果研究，因此这里是产品需求假设与已实现任务范围。

| 用户要解决的问题 | 产品行为 | 不能据此推出 |
| --- | --- | --- |
| 引用是否真实、字段有无写错 | 数据库核验与逐字段差异 | 查不到就一定是编造 |
| 查不到的条目还能不能找到 | AI 检索 Agent 多轮检索，规则确认候选 | Agent 没找到就是编造 |
| 纸质论文、扫描件里的参考文献 | 拍照 / 截图识别，对照原图确认后再核验 | 识别结果不必核对 |
| 引用是否支持正文一句话 | 读取开放全文、检索片段、关系判断、原文引句 | 存在文献就支持论断 |
| 论文里藏着写给 AI 的指令 | 导入时检测隐藏文字，列出并移除 | 没有检出就一定没有 |

## 两个任务，各自保留判断依据

参考文献体检回答元数据问题：记录是否可查、是否同一篇、字段哪里不同、是否存在撤稿或关注标记。规范写法依据已取得的数据库元数据生成，不让模型编写文献信息。

论断证据核查回答有限材料中的关系问题：支持、部分支持、矛盾或证据不足。它不是事实搜索引擎；DOI 只能读到开放获取全文（Europe PMC、arXiv），其余只有摘要。用户文本仅标为用户提供，系统不认证其真实性。

## 验收标准

正常输入要能形成可复核结果；错误、缺配置、取消与证据缺失要有不同状态；导入和识别的文字在应用前可检查；对外展示的功能、测试数字与实际文件一致。性能、准确率与市场价值没有测量依据时不作量化承诺。

# 02 系统架构与数据流

前端采用 Next.js App Router、React、TypeScript 和 Tailwind CSS。服务端模块把文件提取、规则核验与模型调用隔开，模型密钥不进入客户端。




| 边界 | 实现职责 |
| --- | --- |
| 页面与组件 | 输入、来源范围、进度、取消、结果与报告；手机布局 |
| /api/check • /api/agent | 流式参考文献核验；单条 AI 检索的逐步结果 |
| /api/import • /api/vision | 文件提取与隐藏文字检测；图片识别参考文献 |
| /api/claims | 证据获取、混合检索、模型判断与引用校验 |
| pnpm mcp（stdio） | verify_references、check_claim 两个工具开放给 MCP 客户端 |
| lib/verify • agent • claims • documents • vision | 业务逻辑与 UI 解耦；模块测试覆盖各自边界 |

## 信任边界

公开数据库响应、用户文件、图片和模型输出都视为外部输入。数据库结果不等于真实世界全部知识；上传文字不等于可信论文；模型文本也不直接成为程序事实。每条链路在输入、来源、结构和输出位置上设置校验。

# 03 参考文献：工具调用与事实核验

选用 DeepSeek 复用现有配置与中文交互能力，采用受约束的 Function Calling。当前没有与其他模型做质量或成本对照实验，因此不声称它是最优模型。

## 集成方式

标准模式由规则提取条目和字段；AI 模式在数据库查询前加入 verify_references 工具调用。服务端预先固定条目边界，只接受原文可支持的字段。模型不能增删条目、改写原文、覆盖已有错误证据或调用任意工具。

有 DOI 时先取元数据；必要时核对 DOI 注册与内容协商结果。整条引文通过 Crossref 模糊检索，英文条目必要时使用 OpenAlex 兜底。匹配与结论由程序依据取得的数据执行。

| 关键保护 | 用户可见结果 |
| --- | --- |
| 作者、年份、期刊依据保留 | 模型不能把原文中的错误提前修掉 |
| 同篇判定独立于相近候选 | 候选未确认时保留原文并要求人工判断 |
| 撤稿与关注声明分开 | 不同的学术状态不会被合并成同一标签 |
| 连接失败与查无记录分开 | 故障和预算不足记为未完成，不当作不存在 |
| 覆盖范围先核对 | 期刊在引文年份未被 Crossref 收录时，查不到不算证据 |
| 汉字作者与拼音记录 | 跨文字比对作者，不把写法差异判为作者错误 |

## 用真实论文的参考文献调规则

评测集从 Crossref 按出版社随机抽取 2023 年后发表的论文，再从其参考文献中随机取原文，每一条都真实存在。dev 108 条用于调规则；test 119 条在规则定稿前不看、只跑一次。2026-10-15 的修复把 test 误报从 16.0% 降到 10.1%（逐条复核）。

10-16 逐条分析剩下的 12 条误报，修了 9 类规则（题名缩写、会议报告与机构报告、复姓缩写、汉字与拼音、期刊收录年份等）。修后 test 不再算盲测，因此另抽了 110 条来自 81 篇不同论文的新盲测集，待 OpenAlex 额度恢复后运行一次。

# 04 AI 检索 Agent：模型规划检索，规则判定结论

对“无法核验 / 只找到相近候选”的条目，用户可点“AI 继续查”。DeepSeek 阅读原文、已解析字段和已经查过的路径，自己决定下一步调用哪个工具，每一步实时显示在卡片上。




| 约束 | 做法 |
| --- | --- |
| 工具白名单 | search_crossref、search_openalex（每条最多 1 次）、search_datacite、lookup_doi、finish |
| 参数校验 | 工具名、字段、长度、年份范围、DOI 格式；DOI 只能查引文或检索结果中出现过的 |
| 不能下结论 | 模型不能指定哪一篇算数，不能制造“疑似不存在”；含真伪判断词的小结不显示 |
| 预算与失败 | 每条最多 4 次检索、4 轮模型调用、80 秒；失败或超时保持原结论并如实说明 |

## 评测与复核

dev 61 条可追查：确认 3 条，均为已核实。test 58 条是 Agent 的盲测：确认 7 条（4 条已核实、3 条信息有误），没有失败，也没有变成“疑似不存在”；每条平均约 3 次检索、5.5 – 5.8 千 token、10 – 12 秒。

盲测 7 条逐条复核：1 条匹配到同一作者的新文章，1 条是报告的旧版本，据此补了两条保守规则。52 条中文条目 Agent 一条也没找到——知网、万方没有开放接口，这是数据源的限制，不是模型能弥补的。

# 05 论断：开放全文、混合检索与带引句判断

论断接口每次接收一条论断，使用 DOI 或用户文本中的一种。DOI 优先读取开放获取全文，只访问固定的白名单数据源，不接受模型或用户指定的任意地址。




## 证据来源

依次尝试 Europe PMC 开放全文（JATS XML，去掉参考文献、表格内容和公式）、arXiv 预印本 PDF（DOI 本身是 arXiv，或出版社在 Crossref 登记了预印本；PDF 走导入的安全解析器，并排除隐藏文字），都没有才用 Crossref / OpenAlex 摘要。只访问 www.ebi.ac.uk 与 export.arxiv.org，不跟随跳转，XML 最多 6 MiB，PDF 最多 8 MiB。

## 混合检索

多于 6 段时，原论断的 BM25（英文按词、中文按相邻两字）与模型扩展检索词（中英文同义词、缩写）的 BM25 按倒数排名融合取 20 段，再由模型按 0–3 分重排，取前 6 段交给判断。两步输出逐项校验：检索词不能含网址，重排只能用候选片段的编号；失败时退回词面检索并在结果中说明。DeepSeek 没有向量接口，所以没有做向量检索。

## 输出约束

judge_claim 输出结论、解释与引句；服务端核对片段编号与逐字引句，返回规范化文本中的字符区间。引句可定位不保证解释正确；该流程不独立核验撤稿状态。

# 06 论断检索评测

三篇 CC BY 开放获取论文（Walters & Wilder 2023、Kung 等 2023、Bhattacharyya 等 2023），评测时经 Europe PMC 实时获取全文，与产品同一条路径。24 条原文支持的论断：每篇 4 条英文转述、4 条中文表述，用词刻意与原文不同，并标注出处句子。

| 检索方式 | 前 6 段命中率 | MRR | 中文 12 条命中率 |
| --- | --- | --- | --- |
| 词面 BM25（升级前） | 75% | 0.61 | 50% |
| + 模型扩展中英文检索词 | 100% | 0.79 | 100% |
| + 模型重排（现在的默认） | 100% | 0.98 | 100% |

## 解读

24 条的出处句子只有 2 条在摘要里：只读摘要，大多数论断找不到证据，读取开放全文是必要的。中文论断对英文原文时，词面检索只找到一半；查询扩展补上了跨语言的部分，重排把出处片段排到第 1 位（23/24）。

## 局限

样本小；论断由评测者通读全文后编写，而且都是原文支持的说法。三篇论文都不长（14–31 段），重排的 20 段候选覆盖了文档的大部分，长文档上的提升可能更小。这里只评检索，没有评判断准确率。

## 一次真实页面核查

生产构建中输入中文论断“即使用 GPT-4，它引用的书籍章节里也有七成是编造的”和 DOI 10.1038/s41598-023-41032-5：结果为“证据支持”，引句来自论文 Results 一节的原文，判断范围标为 Europe PMC 开放全文，并列出检索方式与扩展检索词。这句话在摘要里没有。

# 07 多模态：拍照 / 截图识别参考文献

扫描版 PDF 没有文字层、纸质论文只能拍照时，用户上传 1–4 张图片或在参考文献框里直接粘贴截图，由 DeepSeek 视觉模型逐条转写。




| 设计 | 说明 |
| --- | --- |
| 只转写，不判断 | 不改错、不补全、不翻译；真伪由后续的数据库核验给出 |
| 图片里的文字是数据 | 不执行图片中的指令；模型只能调用 submit_references |
| 输出校验 | 只接受 entries 字段；最多 80 条、每条 2,000 字符；去掉控制字符 |
| 隐私与限额 | 原图只在请求内存中使用；每 IP 每分钟 4 次、每进程每小时 40 次、同时 2 个 |

## 评测

用 16 条真实文献生成英文截图、中文截图，以及加了纸张底色、倾斜、模糊、噪点和 JPEG 压缩的中英混排“手机照片”：16/16 逐字一致，字符错误率 0%，每张 3–5 秒。识别结果和标准答案分别送去核验，结论完全一致。

这是印刷体合成样本，只说明链路可用、转写不会改变结论；真实拍照的反光、透视和手写批注没有覆盖，所以界面要求对照原图逐条核对。

# 08 文档导入与隐藏提示词检测

导入模块只提取可读文本：PDF.js 读取 PDF 文字层，yauzl 与 saxes 解析 DOCX；文字预览确认后才填入。扫描件没有文字层时，引导用户截图走图片识别。

## 为什么要查隐藏文字

2025 年 7 月，日经亚洲报道 17 篇 arXiv 预印本用白字或极小字号藏了“只给正面评价”之类写给 AI 审稿工具的指令（Sugiyama & Eguchi, 2025）；Lin 的评论文章统计到 18 篇（arXiv:2507.06185）。本项目会把论文交给 AI 解析和论断核查，导入时必须先查一遍。

| 格式 | 检测内容 |
| --- | --- |
| PDF | 白色或接近白色的填充（灰度、RGB、CMYK）、不可见渲染模式、小于 1.5 磅、画在页面外 |
| DOCX | 隐藏格式（含样式继承）、浅色底上的白字、小于 2 磅 |
| 所有格式 | Unicode 标签字符（把 ASCII 指令编码成看不见的字符）与零宽字符 |

## 实现与误报控制

PDF.js 的文字条目不带颜色，取绘图指令又会解码图片（被本项目的解码器防护拦截），因此在已校验哈希的 worker 后追加只读钩子，在提取文字的同一遍里跟踪填充色和渲染模式，不改变提取结果。

像写给 AI 的指令一律列出并从导入文字中去掉；不像指令的，白字短于 40 字、其他方式短于 12 字的按正常排版保留，扫描件的 OCR 文字层只提示。自家 11 页技术说明 PDF 的 24 处深色表头白字没有一处被误报。

资源边界：文件 8 MiB、PDF 100 页、文字 160,000 字符；PDF 单解码缓冲 8 MiB、每文档累计 32 MiB；DOCX 限制条目、展开体积与压缩比，拒绝宏、XML 实体和不安全路径。被图片盖住、透明、裁剪或批注里的文字不在检测范围内。

# 09 MCP Server、可控性与隐私

pnpm mcp 以 stdio 启动 MCP Server（官方 TypeScript SDK 1.31.0），把两个只读工具开放给 Claude、Cursor 等 MCP 客户端，结论与网页端同源。

| 工具 | 输入 | 输出 |
| --- | --- | --- |
| verify_references | 参考文献列表（最多 80 条 / 60,000 字符） | 每条结论、问题、匹配记录与规范写法；逐条发送进度通知 |
| check_claim | 论断，加 doi 或 evidence_text | 四类关系与逐字核对过的原文引句 |

| 场景 | 处理策略 |
| --- | --- |
| 标准文献核查 | 只向公开数据库查询引文，不请求语言模型 |
| AI 解析 / AI 检索 | 向 DeepSeek 发送对应条目；检索工具只访问固定的学术数据源 |
| 图片识别 | 图片发给 DeepSeek；上传前重新编码、去掉 EXIF；原图不保存 |
| 论断核查 | 发送论断、最多 20 段候选和 6 段证据，不是整个文件 |
| 密钥与提示注入 | 密钥只在服务端；材料与图片中的指令一律当数据；未知工具、非法字段一律拒绝 |
| 失败、中止或无证据 | 状态区分；失败不会被替换成支持、矛盾或真实性结论 |

限额以 Node 进程为边界，重启会清零，多实例不共享；公网服务需可信代理、共享限流、账户与费用观测。目前未完成完整负载或渗透测试。

# 10 验证方法与实测结果

以下记录区分离线固定响应、真实网络与浏览器操作。测试通过只覆盖列出的样本和版本，不推导真实世界总体准确率。

| 层级 | 实测记录 | 解释范围 |
| --- | --- | --- |
| 自动测试 | 33 个文件 459 项；lint、类型检查、生产构建通过 | 固定上游响应，覆盖边界与回归 |
| 自建文献样例 | 29/29；编造 7/7；真实文献误判“不存在” 0/15 | 真实联网，自建小样本 |
| 真实论文参考文献 | test 119 条盲测：误报 16.0% → 10.1%（逐条复核） | 10-15 盲测一次 |
| 10-16 误报修复 | 12 条误报逐条复测全部消除；只用 Crossref 的新旧对照中 test“信息有误” 9 → 3，均为真实错误 | 修后不再算盲测；新盲测集 110 条待运行 |
| AI 检索 Agent | test 58 条：确认 7 条，没有失败，也没有判为疑似不存在 | Agent 的首次盲测 |
| 图片识别 | 16/16 逐字一致，字符错误率 0% | 合成印刷体样本 |
| 论断检索 | 前 6 段命中率 75% → 100%，MRR 0.61 → 0.98 | 24 条，评测者编写 |
| 隐藏提示词 | 夹具中 PDF 6 处、DOCX 4 处、TXT 1 处全部检出；自家 PDF 无误报 | 合成夹具 + 真实 PDF |
| MCP 与真实模型 | 两个工具真实调用通过；论断冒烟 4/4 | 流程可用，不是准确率 |

## 评测限制

自建样本量小且有选样偏差；合成材料只检查行为，不是真实研究结果。没有跨领域大样本的判断准确率、标注一致性、用户效率或商业转化研究。新盲测集要用 OpenAlex 题名检索（无 key 时每天约 100 次），结果出来后补充，不提前估计。

# 11 运行、配置与复现

当前交付为本地源码与验收材料，不等于已完成公网部署或正式赛事提交。评审应使用自己的服务端密钥，复现时保留时间、输入、模型名称与结果。

| 步骤 | 执行或配置 |
| --- | --- |
| 环境 | Node.js 22.13+；pnpm；以 package.json 和 pnpm-lock.yaml 为准 |
| 安装 | pnpm install；复制 .env.example 为 .env.local，已有配置不覆盖 |
| AI 配置 | DEEPSEEK_API_KEY；可选 DEEPSEEK_MODEL、DEEPSEEK_BASE_URL |
| 数据库配置 | 建议设置 CROSSREF_MAILTO、OPENALEX_API_KEY；只保留在服务端 |
| 开发 / 生产 | pnpm dev；pnpm build 后 pnpm start --port 3210 |
| MCP Server | pnpm --silent --dir <项目目录> mcp（stdio） |
| 质量检查 | pnpm test；pnpm lint；pnpm typecheck；pnpm build |
| 联网评测 | pnpm eval:real、eval:agent、eval:vision、eval:retrieval；pnpm sample:real 抽新盲测集 |

## 复现注意

没有 AI 密钥时仍可使用标准文献核验；AI 解析、Agent、图片识别和论断判断需要模型配置。公开数据库和模型会变化，复现记录应保存时间、输入、配置的模型名称与结果，不保存密钥。OpenAlex 无 key 时额度很少，连续全量评测会触发 Crossref 限流，评测需分开运行。

自动测试中的固定上游响应保证可重复性，但不能证明当天外部服务可用；真实联网测试会产生少量模型费用，也不能代替离线边界测试。

公网演示是官方可选加分项。本轮没有对外发布授权，不把本地端口写成可公网访问链接；正式提交前另行验证评审访问。

# 12 创新点、局限与发展方向

创新定位是应用与工程组合：把 AI 引用问题拆成可追溯的事实核验和证据核查，而不是声称新的基础模型或检索算法。

| 层面 | 当前设计价值 | 尚缺证据 |
| --- | --- | --- |
| 应用 | 文献事实与正文证据分开；从格式走向可复核判断 | 真实用户规模和效率改善 |
| 技术 | Agent 只找证据、规则下结论；开放全文 + 跨语言混合检索；隐藏提示词检测 | 跨模型比较与长文档检索消融 |
| 交互 | 保留错误原文、来源范围、失败状态与 Agent 的检索理由 | 系统可用性研究与无障碍完整评估 |
| 社会价值 | 帮写作者发现引用问题，识别写给 AI 的隐藏指令 | 真实教学或学术场景的效果研究 |
| 商业 | 图书馆、写作中心、期刊投稿前检查 | 付费意愿、单位成本、转化及留存 |

## 已经明确的局限

开放数据库覆盖不完整，知网、万方没有开放接口，中文条目 Agent 也找不到；中文题名对英文元数据仍无法比对。开放全文只覆盖 Europe PMC 开放获取子集和 arXiv，预印本可能与正式版本不同。图片识别只转写参考文献，未覆盖手写、强反光和严重透视。隐藏文字检测不覆盖被图片盖住、透明、裁剪或批注里的文字。没有账户、计费与公网运营。

## 下一阶段优先级

先在新盲测集上运行一次，报告误报率；在长文档上做检索消融；找真实写作者试用，测量复核时间与误报成本；再决定公网部署、远程 MCP 与机构试点是否值得投入。

# 13 证据索引与提交对应

本地路径以下按项目根目录 D:/Darks/projects/cite-checkup 表示。复核时先查看最终状态文件，再核对实际文件，避免把旧版本验收当成新版本。

| 证据 | 项目内位置 / 说明 |
| --- | --- |
| 最终项目状态 | PROJECT_STATE.md；作为索引，关键结果需核对实际文件 |
| 真实论文参考文献 | eval/real-world/（dev、test、blind-2026-10-16）；<br>eval/results/real-*-2026-10-15-*.json |
| 自建文献回归 | eval/results/curated-2026-10-15-v2.json |
| AI 检索 Agent | eval/results/agent-dev-2026-10-15.json、agent-test-2026-10-15.json |
| 图片识别 | eval/vision/cases.json；eval/results/vision-2026-10-16.json |
| 论断检索 | eval/claims-retrieval/cases.json；eval/results/retrieval-2026-10-16.json |
| 隐藏提示词 | src/lib/documents/__tests__/fixtures/generate_hidden.py 及生成的夹具 |
| MCP 实连 | eval/results/mcp-smoke-2026-10-16T00-35-59-125Z.json |
| 讲稿与内容源 | docs/competition/ 下 narration.json、DEMO_SCRIPT.md、DEFENSE_QA.md、<br>technical-content.json |

## 官方材料要求对应

官方要求技术 PDF 不超过 30 页，包含概述、需求、架构、AI、实现、测试部署和展望。本报告共 14 页，对应这些部分；AI 选型、集成、优化和创新均单独说明。

正式视频须为 5－8 分钟、MP4、至少 1080p、普通话讲解。代码仓库需可供评审访问、保留真实历史并补齐团队资料。本轮不代为报名、公开仓库或提交赛事。官方页面核对日期为 2026-10-14。

官方来源：https://www.boxuegu.com/matchTrack/detail/?id=10037

参考：Sugiyama, S., & Eguchi, R. (2025). Nikkei Asia. https://asia.nikkei.com/Business/Technology/Artificial-intelligence/Positive-review-only-Researchers-hide-AI-prompts-in-papers

参考：Lin, Z. (2025). Hidden Prompts in Manuscripts Exploit AI-Assisted Peer Review. https://doi.org/10.48550/arXiv.2507.06185