引用体检：答辩问答

> 以最终源码和验收证据为准。每题先给**短答**（20–40 秒，可以背），被追问再讲**展开**；**出处**是能当场翻出来的文件。现场展示失败时如实说明，不把目标行为当作成功记录。 配套阅读：答辩准备手册（队员版）。数字口径（旧口径 / 新口径、盲测 / 回归 / 同一批复测）见手册第 6 节。 2026-10-26 起按类别重新编号，原第 1–26 题的对照表在文末。

目录

- **A 项目定位与需求**：A1–A8
- **B 大模型与整体 AI 设计**：B1–B8
- **C AI 检索 Agent**：C1–C5
- **D 论断 RAG**：D1–D7
- **E 多模态**：E1–E3
- **F MCP 与工具**：F1–F3
- **G 安全与隐私**：G1–G6
- **H 核验规则与准确率**：H1–H11
- **I 中文文献**：I1–I5
- **J 工程实现**：J1–J9
- **K 前端与交互体验**：K1–K4
- **L 创新与同类工具**：L1–L3
- **M 社会价值与商业**：M1–M4
- **N 局限与下一步**：N1–N3
- **O 团队与开发过程**：O1–O3
- **P 现场演示**：P1–P3

A 项目定位与需求

A1 这个项目是做什么的?

短答：引用体检是一个网页工具，帮写论文的人检查参考文献是不是真的、信息写得对不对、有没有被撤稿，还能检查正文里的一句话有没有被引用的材料支持。大模型只负责找和读，真假由规则根据数据库记录判定，每个结论都附原始依据。

展开：

- 两个工作区：“参考文献体检”逐条给结论印章；“正文论断核查”找原文句子判断支持关系。
- 六项 AI 能力：受约束字段解析、AI 检索 Agent、中文期刊联网核查、截图识别、论断 RAG、MCP Server；导入时另有隐藏提示词检测。
- 在线试用：魔搭创空间，不用登录。

出处：README 开头；技术说明封面。

A2 为什么要做? 问题有多严重?

短答：大模型写作会编造参考文献。Walters 和 Wilder 2023 年的研究里，GPT-3.5 生成的引文 55% 是编造的，GPT-4 是 18%。另外 2025 年还出现了在论文里藏给 AI 审稿的隐藏指令。学生、老师逐条手工核对很费时间，直接问 AI 又不可靠。

展开：

- 出处：Walters, W. H., & Wilder, E. I. (2023). *Scientific Reports*, 13, 14045. https://doi.org/10.1038/s41598-023-41032-5。比例只代表该研究的样本，不代表当前所有模型。
- 隐藏指令：日经亚洲 2025 年 7 月报道 17 篇 arXiv 预印本藏了写给 AI 审稿的指令；Lin（arXiv:2507.06185）统计到 18 篇。
- 不能直接问 AI 的证据见 A6。

出处：README 开头引文；技术说明第 1 节。

A3 目标用户是谁?

短答：主要是用 AI 辅助写作、提交前要自查参考文献的学生；其次是指导老师和审稿人；长远看是高校图书馆、写作中心这类机构。

展开：

- 学生：交稿前把参考文献整份贴进来，几十秒拿到逐条结论和规范写法。
- 老师：批量核查学生论文的参考文献，重点看“需要处理”的条目。
- 机构试点（图书馆、写作中心）还只是设想，没有做过访谈或试点（见 M2）。

A4 参考文献核查和论断核查为什么要分开?

短答：因为是两个不同的问题。文献存在、信息写对，不代表正文那句话被它支持；反过来，一句话被原文支持，引文格式也可能写错。分开查、分开下结论，用户才知道到底哪里有问题。

展开：参考文献核查依据数据库元数据；论断核查依据原文片段（全文或摘要）。两边的证据来源、判断方式都不同，混在一起会把“文献真实”误读成“论断正确”（见 D4）。

A5 和普通文献管理软件（如 EndNote、Zotero）有什么区别?

短答：文献管理软件管理你已经有的文献、帮你排格式；我们核查别人（或 AI）写好的引文是不是真的、写得对不对，而且原文里的错误不会被格式化隐藏，结果附查询轨迹和原文引句。

展开：我们没有文献库管理、协作写作等功能，也没有和这类软件做系统对照研究。“规范参考文献”只用数据库记录重写确认过的条目，没确认的保留原文并注明原因。

A6 为什么不直接问 ChatGPT、DeepSeek?

短答：我们做过对照：130 条答案已知的引文，不联网直接问 DeepSeek，会把 23%–33% 的编造引文说成真实，本系统是 0。联网的 AI 好很多，是真正的对手。但本系统说“已核实”的全部正确，改正写法全部来自数据库，重跑结论一致，单条约 2 秒。

展开：

- 数据集：真实 50、改错一项 40、编造 40，含中文 20。条件对 AI 有利：开深度思考、逐条单独问、允许答“不确定”。
- 不联网：编造说成真实 23%–33%，改错说成正确 13%–18%，给出的 DOI 只有 56%–63% 指向正确论文，同一条问两次有 12% 结论会变。
- 联网 flash：同样没放过编造和改错，真实英文条目 40/40 有结论（我们 20/40），覆盖更广。
- 联网 pro：仍把 2 条改过 DOI 的引文说成一致，两次运行有 17% 结论不同，单条 8–24 秒。
- 本系统：已核实 19/19 全对，改正写法 36/36，重跑 129/130 一致，规则核验不调用模型。
- 短处：网页、报告、图书多判“待人工”，也不检查格式是否完整，这两点联网 AI 做得更好。
- 中文补跑（标准体检加了联网核查后，这批已看过只算回归）：虚构 10 条没有一条判成已核实或有误；真实 10 条已核实 3 条、其余 7 条给出引文那篇的链接；中文每条平均约 12 秒。

出处：技术说明第 15 节；`docs/competition/COMPARISON-2026-10-18.md`。

A7 只能查错吗？能不能直接帮学生生成规范的参考文献？

短答：能，但只用数据库记录生成，不让模型编。体检后点“规范参考文献”，整份列表可以统一成 GB/T 7714 或 APA；确认是同一篇的按记录重写，没确认的保留原文并注明原因。只贴 DOI 也能补全成完整条目。

展开：

- 相近候选、查不到、待人工的条目保留原文，末尾写明原因，不替用户猜。APA 按第一作者排序、不编号。
- 只贴 DOI 时按 DOI 补全题名、作者、期刊、卷期页，照常查撤稿。
- 这个功能做出来之前，只贴 DOI 的条目会因为没有题名可比被误判成“DOI 指向另一篇文献”，已修复并补了测试。
- 场景测试：Crossref 随机抽 30 篇，生成条目的 8 项字段 30/30 与数据库一致（第一次 27/30，修了 Crossref 把作者单位登记成作者的问题）。
- 覆盖面和核查一样：英文期刊、会议论文好，中文图书、学位论文多数只能保留原文。

A8 在线演示在哪里？为什么打开要等？

短答：部署在魔搭创空间（Docker，免费 2 核资源），不用登录，电脑手机都能用。从打开到出现界面有时要十几到三十秒（10-23 实测桌面约 5 秒），时间几乎都花在平台页面本身，应用被请求后 1 秒内就绪。

展开：这是免费演示环境，有几个限制：

- 单实例运行，所有访客共用 AI 调用额度。
- 接近 8 MiB 的上传在平台上没有验证通过，建议上传小文件或直接粘贴文字。
- 正式服务需要独立服务器、可信代理、共享限流和费用监控，这些写在展望里，还没有做。

B 大模型与整体 AI 设计

B1 为什么需要模型，而不是只查数据库？

短答：文献是否存在，适合由结构化数据库回答；但杂乱引文的字段提取、找不到时换思路检索、自然语言论断和证据之间的关系，适合由模型辅助。我们把两者串成受约束的工作流：模型负责“读”和“找”，服务端负责校验输入输出、给出可验证的来源。

B2 这是不是给聊天接口套了个页面？

短答：不是。提示词之外，系统实现了引文切分、字段验证、多个学术数据源的比对、逐字段同一篇判定、中文网页证据链、证据分块检索、引句溯源、失败兜底、取消和报告，可以现场打开源码和测试。但它是有限范围的应用，不宣称在模型或检索算法上有研究创新。

展开：源码约 1.2 万行，728 项测试；判断真伪的部分（`verify.ts`、`match.ts`）完全不调用模型。

B3 为什么选 DeepSeek？比较过别的模型吗？

短答：DeepSeek 中文理解好，支持函数调用、多轮工具调用和图片输入，还有一个能查中文期刊的搜索接口，国内能直接访问，部署和计费简单。我们没有做多模型的质量和成本对照，所以不声称它最优。

展开：对照实验里比较的是“直接问 DeepSeek”和“本系统”，不是不同模型之间的比较。模型名和接口地址可以通过环境变量更换，默认 `deepseek-flash`。

B4 模型具体用在哪几处？哪些地方不用？

短答：用在六处：字段解析、AI 继续查、截图转写，以及论断核查的查询扩展、重排、判断和范围复核。中文期刊联网核查用的是 DeepSeek 的搜索接口，那是搜索引擎，不是大模型。真伪判定、是不是同一篇、规范写法生成，一律不用模型。

展开：标准体检（不开 AI 辅助解析）不调用大模型；没有配置密钥时，标准体检照常可用，只是跳过中文联网核查。

B5 “AI 辅助解析”到底有没有用？

短答：有一点，但很小。它只在规则解析不出题名时，把那几条交给模型从原文逐字摘字段，逐条核对确是原文片段。同一批数据对照：test 集多核实 2 条、多抓出 1 条真错误，没有新增误报；dev 和第五批结论逐条相同。

展开：

- 摘出的刊名不用于比对；AI 摘出的题名查不到时，不作为“疑似不存在”的依据。
- 旧版把整份列表交给模型、一条不合格就整批作废，对照里反而多了误报，所以改成现在逐条的做法。
- 默认关闭，打开时页面提示发送了几条、补上几条、退回几条；单次最多 20,000 字符。

出处：README“AI 辅助解析”一节；`eval/results/ai-parsing-ab-2026-10-17.json`。

B6 怎么防止模型编造（编引句、改原文、给假 DOI）？

短答：模型输出一律当作外部输入校验。字段必须是原文片段；引句必须能在证据里逐字找到并定位；DOI 只能查引文或检索结果里出现过的；结论由规则给出，模型没有“宣布真伪”的出口。

展开：

- 论断核查只接受允许的结果类别、有效的片段编号和能定位的引句；假引句、错来源不能成为通过校验的证据。
- 精确匹配只证明引句确实存在，不证明模型解释一定对，所以保留原文和人工复核入口。
- 字段解析不能增删条目、改写原文或覆盖原文里的错误证据。

B7 Function Calling 是怎么做的？参数怎么校验？

短答：每个场景只给模型一个或几个白名单工具：字段解析只有 `verify_references`，截图只有 `submit_references`，论断判断只有 `judge_claim`，Agent 有 6 个检索工具。服务端逐项校验工具名、字段、长度、格式；未知工具、非法字段、截断或超大响应一律拒绝。

展开：DeepSeek 偶尔把参数再包一层 `{"arguments": {...}}`，我们只拆这一种已知外壳，拆开后仍严格校验（`src/lib/tool-args.ts`）。这是测试中发现的真实问题：判断正确却被拒，原因就是这层外壳。

B8 模型调用失败、超时怎么办？

短答：明确降级，不伪造结果。AI 解析失败就回退规则解析并提示；Agent 失败保持原结论；论断核查失败标“未完成”。已知的瞬时连接错误最多重试一次，共用 60 秒总超时。

展开：

- 鉴权失败、HTTP 错误、内容校验失败不重试。
- 生产日志只输出固定的错误分类，不记录引文、密钥或原始异常。

C AI 检索 Agent

C1 是自主 Agent 吗？

短答：“AI 继续查”是一个检索 Agent：对无法核验或只有相近候选的条目，DeepSeek 多轮决定下一步调用哪个检索工具、用什么检索词，每一步写理由并实时显示。但自主范围刻意收窄：它只能找证据，候选由规则逐字段确认，不能指定哪一篇算数，也不能把文献判成编造。

展开：

- 规则一旦确认找到同一篇就停；每条最多 4 次检索、4 轮、80 秒。
- 标准体检本身也会对 Crossref 确认不了的中文期刊论文自动联网核查一次（见 I1）。那一步只用搜索接口和公开页面，不调用大模型。

C2 Agent 一次追查是怎么进行的？有哪些工具？

短答：

1. 把引文、已解析的字段和已经查过的路径交给模型。
2. 模型选工具、给检索词和理由。
3. 服务端校验后执行检索。
4. 规则逐字段比对候选，确认就停，否则把精简后的候选和比对提示回给模型，进入下一轮。

工具有 6 个：`search_crossref`、`search_openalex`、`search_datacite`、`search_cn_journals`、`lookup_doi`、`finish`。

展开：OpenAlex 每条最多 1 次；模型写的理由和小结会去掉网址，只作为过程说明。代码在 `src/lib/agent/index.ts`（循环）、`tools.ts`（工具与校验）、`model.ts`（模型调用）。

C3 Agent 会不会把真实文献判成编造？

短答：不会，这是设计约束：Agent 的检索不计入“两个数据源都查不到”的判定，它的输出也不能产生“疑似不存在”。test 盲测 58 条里 0 条变成疑似不存在；中文 75 条同样 0 条。

展开：

- 英文：test 集 58 条可追查的条目确认 7 条，没有失败、没有判成不存在。复核发现 1 条配到同一作者的新文章、1 条是报告旧版本，据此补了两条更保守的规则。
- 中文：10-15 的评测里 52 条中文一条没找到，其中 47 条是因为 OpenAlex 额度用完没查；10-17 额度给足重测，仍然 0 条，说明这几个开放数据库确实收录不到。加了知网、万方、维普的联网搜索后，75 条中文找到三站论文页 33 条、确认 1 条，没有一条变成疑似不存在，也没有把别的文章确认成同一篇。

C4 Agent 的效果如何？值得吗？

短答：在英文上能多找回一小部分：test 58 条确认 7 条。中文能找到三站论文页的大约一半，但多数缺作者，只能给链接请人核对。它的价值在于把“待人工”变成“附候选和链接的待人工”，减少人工检索时间，而不是自动判真伪。

展开：每条平均约 3 次检索、5.5–5.8 千 token、7–12 秒。

C5 为什么限制 Agent 的自主权？会不会限制太多？

短答：查证类任务里，模型最大的风险是替人下结论，说“有”其实没有。让它只负责找，结论仍由规则给，就不会出现这种错误；代价是有些能找到的文献只能停在“相近候选”。我们宁可多留给人工，也不让模型制造确定性。

D 论断 RAG

D1 论断核查的完整流程是什么?

短答:

1. 按 DOI 取证据:先读 Europe PMC 或 arXiv 的开放全文,没有就用摘要;也可以直接粘贴材料。
2. 按约 1,200 字符分块。
3. 长材料用混合检索:原论断的 BM25,加模型扩展的中英文检索词,倒数排名融合取 20 段,再由模型重排取前 6 段。
4. 模型判断四类关系之一,服务端逐字校验引句并定位。
5. 初判“矛盾”时再做一次范围复核。

出处:README“技术架构”;技术说明第 7 节;`src/lib/claims/`。

D2 RAG 为什么不用向量数据库?

短答:DeepSeek 没有向量(embedding)接口,引入另一家服务会增加依赖和数据外发。我们用“BM25 + 模型扩展中英文检索词 + 模型重排”补语义和跨语言召回:24 条论断的前 6 段命中率从 75% 提高到 100%,MRR 从 0.61 到 0.98。

展开:

- 纯 BM25 对中文论断只有 50%,因为中文论断对英文原文时词面对不上,查询扩展补上了这一半。
- 样本小、论断由评测者编写、文档也不长,只说明方向有效,没有和向量检索直接比较。

D3 证据从哪里来?读不到全文怎么办?

短答:DOI 依次尝试 Europe PMC 开放全文(JATS XML,去掉参考文献、表格和公式)、arXiv 预印本 PDF,都没有时用 Crossref 或 OpenAlex 摘要;用户也可以直接粘贴材料。结果会写明读到的是全文还是摘要,因为摘要能支持的结论有限。

展开:

- 全文只访问 `www.ebi.ac.uk` 和 `export.arxiv.org` 两个固定主机,不跟随跳转。XML 最多 6 MiB,PDF 最多 8 MiB,正文最多 150,000 字符。
- PDF 走和导入相同的安全解析器,包括隐藏文字检测。
- 24 条评测论断的出处句子只有 2 条在摘要里,所以全文很重要。

D4 引文找得到,就意味着论断正确吗?

短答:不能。元数据核验只确认文献和字段;论断核查是独立流程。即使论文真实存在,它也可能不支持你写的那句话。

展开:摘要能提供的上下文比全文少;用户粘贴的材料真实性没有自动认证。结论必须和来源类型、召回范围一起看。

D5 论断核查的 AI 判断会不会出错？怎么防？

短答：会。我们在测试里抓到过一类典型错误：只能读摘要时，模型拿“总体”结果去否定限定了子类的论断。现在初判为矛盾时会再做一次范围复核，限定词没被引句覆盖就改判“证据不足”。47 条论断两轮验证，不该判矛盾的 178 次里错判从 38 次降到 0。

展开：

- 例子：摘要只说 GPT-4 引文总体 18% 是编造的，模型就把“GPT-4 引用的书籍章节七成是编造的”判成矛盾；正确结论是证据不足。
- 范围复核：让模型逐个列出论断里限定范围的词（文献类型、人群、年份、条件），检查引句是否专门针对它。
- 该判矛盾的 102 次里，有 1 次被错改成证据不足。
- 这套论断是我们自己写的，只针对这一类错误，不代表总体准确率；需要推理才能看出的矛盾，判定本身仍然判不出来。所以结论旁一定附原文引句和判断范围。

出处：`docs/competition/CLAIM-SCOPE-2026-10-19.md`。

D6 检索效果是怎么评测的？

短答：取三篇 CC BY 开放获取论文的全文，评测者通读后写了 24 条原文确实支持的论断（中英各半、用词刻意与原文不同），标出出处句子，看召回的前 6 段里有没有出处句子。

展开：

检索方式	命中率	MRR
纯 BM25	75%	0.61
加查询扩展	100%	0.79
再加重排	100%	0.98

只评检索，不评判断；论断全是原文支持的说法，样本小、文档不长。

D7 四类判断分别是什么意思？

短答：

- **证据支持**：引句直接支持论断。
- **部分支持**：支持一部分，或范围、程度不完全一致。
- **与证据矛盾**：引句给出相反结果。
- **证据不足**：找不到足以判断的内容。

每类都附原文引句和位置；没有引句的不能判支持或矛盾。

E 多模态

E1 多模态做了什么？PDF / DOCX 导入算吗?

短答：PDF / DOCX 导入只是文字提取，不算多模态。多模态是“拍照 / 截图识别”：DeepSeek 视觉模型逐条转写图片里的参考文献，只转写、不判断真伪，看不清写 `[?]`，用户对照原图确认后再交给规则核验。

展开：

- 图片在浏览器里先缩到 2048 像素以内、去掉 EXIF；每次 1–4 张。
- 合成的 16 条（英文截图 5、中文截图 5、模拟手机照片 6）16/16 逐字一致，字符错误率 0%。
- 这是印刷体合成样本，手写、强反光、严重透视没有覆盖。

E2 识别错了怎么办?

短答：识别结果先显示在预览里，和原图并排，用户可以直接改；确认后才进入核验。而且识别错的字段会在核验时和数据库对不上，被标出来，不会被“悄悄修好”。

E3 图片会被保存吗?

短答：不会。原图只在请求内存里使用；上传前在浏览器重新编码，去掉位置等 EXIF 元数据。图片会发给 DeepSeek 做识别，页面上有说明。

F MCP 与工具

F1 你们的 MCP Server 能做什么?

短答：用官方 TypeScript SDK 以 stdio 提供两个只读工具：`verify_references` 核验参考文献，`check_claim` 核查论断。Claude Desktop、Cursor 等 MCP 客户端可以直接调用，和网页端用的是同一套逻辑。

展开：

- 返回文字摘要和带输出结构定义（outputSchema）的结构化结果；核验时逐条发送进度通知。
- 输入上限：80 条 / 60,000 字符。
- 目前只在本机以 stdio 运行，没有远程 HTTP 部署和鉴权。

出处：README“MCP Server”；`pnpm smoke:mcp` 记录。

F2 MCP 和 Function Calling 有什么区别?

短答：Function Calling 是我们调用模型时，让模型按我们定义的工具格式输出参数，是“我们用模型”。MCP 是把我们的能力做成标准工具，让别的 AI 来调用，是“别的 AI 用我们”。两者方向相反。

F3 MCP 怎么验证真的能用?

短答：`pnpm smoke:mcp` 用和 Claude 客户端相同的命令启动服务端，列出工具并真实调用两个工具：两条公开文献一条已核实、一条查出年份写错；DOI 摘要论断判为“证据支持”并附原文引句。

展开：演示时可以用“本地 MCP 演示客户端”页面，它是真实 SDK 的 stdio 客户端，不是 Claude 或 Cursor 的界面，要说清楚。

G 安全与隐私

G1 提示注入和恶意文件安全吗?

短答：上传内容和网页内容都只当作待分析的数据，不能让系统执行命令或访问任意网址；模型输出经过结构和来源校验。导入器有文件、页数、字数、解压上限，PDF.js worker 做完整 SHA 校验，不支持或损坏的文件直接拒绝。

展开：

- 上限：文件 8 MiB（Netlify 版 4 MiB）、100 页、160,000 字符。
- PDF 解码预算：单缓冲 8 MiB、累计 32 MiB。这是解码缓冲预算，不是进程内存硬上限。
- ZIP 有条目数、总量、压缩比限制，防解压炸弹。
- 不能据此证明所有恶意文档都能拦截。导入时还会检测隐藏提示词（G2）。

G2 隐藏提示词检测查什么？会不会误报?

短答：检查读者看不见、AI 却会读到的文字：PDF 的白字、不可见渲染、极小字号、页面外文字，Word 的隐藏格式和白字，以及所有格式里的 Unicode 隐形标签字符。像写给 AI 的指令一律列出并从导入文字中去掉；不判断作者意图。

展开：

- 背景：日经亚洲报道 17 篇 arXiv 预印本藏了写给 AI 审稿的指令（Lin 统计到 18 篇）。
- 降低误报的规则：
  - 白字短于 40 字、其他方式短于 12 字且不像指令的，按正常排版保留。
  - 扫描件的 OCR 文字层只提示，但要求页面画了覆盖过半版面的图像；OCR 层里像指令的行照样报告。
- 实测：
  - 测试夹具里 PDF 6 处、DOCX 4 处、TXT 1 处全部检出。
  - 自家技术说明 PDF（当时的 11 页版）里 24 处深色表头白字没有误报。
  - 被图片盖住、透明或批注里的文字不在检测范围内。

G3 用户数据发给谁?

短答:

- **标准体检**:查询公开学术数据库。配置了 DeepSeek 密钥时,Crossref 确认不了的中文期刊论文,会把题名发给 DeepSeek 的搜索接口,再读取知网、期刊官网的公开页面。
- **AI 功能**:只有主动使用时,才把相关引文或证据片段发给 DeepSeek 的大模型。
- **密钥**:只在服务端。

展开:

- 论断核查最多发 20 段候选片段(重排)和最终 6 段(判断)。
- 图片识别会把图片发给 DeepSeek,原图不保存。
- 读页面只读不登录、不带 cookie、不碰验证码页。
- 建议只处理有权处理的文本,不把未公开论文默认发给模型。

G4 服务器替用户访问网页,会不会被利用(SSRF)?

短答:会有这个风险,所以做了防护:中文核查要访问的期刊官网网址来自搜索结果,服务器只请求公网地址,逐跳检查跳转,拦截本机、内网、链路本地(含云服务器元数据 169.254.169.254)地址、非常见端口和带账号的网址。

展开:开放全文只访问两个固定主机;Agent 的工具只能查固定的学术数据源,模型不能指定网址。这些防护都有单元测试(`cnpage-safety.test.ts`)。

G5 API 密钥怎么保护?

短答:密钥只放在服务端环境变量(本地 `.env.local`,魔搭用平台的 Secrets),仓库只提交 `.env.example`;前端拿到的只有"AI 是否可用"的状态。提交历史检查过没有密钥。

G6 怎么控制费用和网络故障?

短答：先本地解析和检索，限制输入、并发和调用预算；各接口按 IP、按进程限流，超出时明确提示或回退规则核验。数据源出错标“未完成”，不当作“不存在”。

展开：

功能	限额
核查	每 IP 每分钟 6 次，每次 80 条 / 60,000 字符
AI 解析	每 IP 每分钟 2 次、每进程每小时 30 次、同时 2 次
Agent	每 IP 每分钟 6 次、每小时 60 次
图片识别	每 IP 每分钟 4 次、每小时 40 次
论断核查	每 IP 每分钟 6 次、每小时 30 次

- 外部请求按主机限流，429 / 5xx 退避重试，结果做内存缓存。
- 限额只在单进程内计数，未做多实例共享和账户计费，正式服务前需要补。

H 核验规则与准确率

H1 一条参考文献是怎么被核查的?

短答：

1. 本地解析出 DOI、年份、题名、作者、期刊。
2. 有 DOI 先按 DOI 查 Crossref，查不到再问 doi.org 是否注册、取元数据。
3. DOI 没对上就用整条引文检索 Crossref；英文还找不到用 OpenAlex 题名检索兜底，中文期刊论文联网核查。
4. 对候选逐字段打分，选出最佳匹配，查撤稿，给出结论、规范写法和每一步的核查过程。

出处：README“核查流程”；`src/lib/verify/verify.ts`。

H2 怎么判断数据库里那条记录和引文是“同一篇”?

短答：不是先把引文完美解析，而是拿数据库记录的题名、作者、期刊回到引文原文里找：题名按词（中文按相邻两字）算重合度，作者逐个定位并看顺序，再比年份、期刊、卷页、DOI。题名几乎一致且作者或年份期刊对得上，才算同一篇。

展开：

- 短题名要求更严；图书、报告年份差得远时要求题名几乎逐字一致；中文网页记录要求题名、刊名、年份都对上。
- 作者支持汉字与拼音互相比对。
- 代码在 `src/lib/verify/match.ts` 的 `scoreCandidate`。

H3 八种结论分别是什么意思?

短答:

- **已核实**:一致。
- **有误**:同一篇但写错,或 DOI 未注册 / 指向别的文献。
- **相近候选**:找到相近记录但不能确认是同一篇。
- **查无此文**:有较强证据表明不存在。
- **已撤稿**:撤稿或撤回。
- **关注声明**:期刊关注声明,不等于撤稿。
- **待人工**:超出覆盖范围,或中文联网也没核对到。
- **未完成**:数据源出错,可重试。

展开:判“查无此文”要有较强证据:

- DOI 未注册,或 DOI 指向别的文献;
- 或者看得出是期刊、会议论文的英文文献,在 Crossref 和 OpenAlex 都查不到。

图书、网页、学位论文查不到只判“待人工”。

H4 29/29 是准确率 100% 吗?

短答:不是。这是预先定义的 29 条小型自建回归用例全部符合预期(编造检出 7/7,真实文献误判不存在 0/15),用来防止改坏,不能代表总体准确率。真实场景的数字看盲测(H5)。

H5 真实论文的盲测结果怎么解读?

短答：我们从 Crossref 随机抽真实论文的参考文献（都真实存在），每批约 110 条，规则定稿后只跑一次，逐条复核。按旧口径（相近候选也算误报）：

- test 集 10.1%。
- 第二到五批分别是 9.1%、11.7%、18.0%、5.6%。

修过的类型在看过的数据上清零，但新数据会出现新的长尾，所以误报没有稳定降下来。

展开：

- dev 108 条用于调规则；test 119 条在规则定稿前不看，修复后误报从 16.0% 降到 10.1%（12/119）。
- 第二批：64 篇论文 110 条，9.1%（95% 区间 5.0%–15.9%）。
- 第三批：62 篇论文 111 条，11.7%（7.0%–19.0%），其中 6 条是相近候选。
- 第四批：63 篇论文 111 条，18.0%（12.0%–26.2%）。Cambridge 一组 12 条里 7 条引的是法律政策文件、专利、航海标准等覆盖不到的文献；不算相近候选是 15.3%；这批还正确标出 3 条作者真写错的引文。
- 第五批：按第四批的原因修过之后另抽，63 篇论文 108 条，5.6%（2.6%–11.6%），不算相近候选是 4.6%。它比前几批低，但区间与前三批重叠，也可能只是这批覆盖范围外的文献少。
- 误报全是英文条目；每批只有一百多条，同一篇论文的条目常一起出错，复核由我们自己完成、没有独立标注，差别要谨慎解读。

出处：技术说明第 4、13 节；`eval/results/real-*-adjudication.json`。

H6 “相近候选”为什么不算信息有误？会不会把真错误藏起来?

短答：只找到题名相近的记录、没能确认是同一篇时，说不上引文哪一项写错，所以单列为“相近候选”。它照样展开字段比对和候选写法、单独计数、可以点 AI 继续查，不会被当成“已核实”埋掉。

展开：

- DOI 未注册或指向别的文献时，DOI 的错误是确定的，即使另有相近候选也判“有误”。
- 三次盲测复核出的误报里相近候选共 9 条，没有一条是引文真写错了，这是改口径的原因。
- 在第四批上检验，相近候选 3 条，误报从旧口径 18.0% 降到新口径 15.3%；其余误报来自覆盖范围外的文献类型和引文格式，单列解决不了。

H7 查不到，就是编造吗?

短答：不是。查不到只说明开放数据库里没有，图书、学位论文、网页、标准、很多中文文献本来就不在覆盖范围，这时判“待人工”并写明“查不到不代表不存在”。只有 DOI 证据确定，或英文期刊论文在两个数据库都查不到时，才判“查无此文”，而且仍提示人工复核。

展开：判“查无此文”之前还会检查引文写的期刊在该年份是否在 Crossref 收录范围内（有的期刊只登记了某几年），不在范围内就改判待人工。

H8 撤稿是怎么查的?

短答：Crossref 记录里带 Retraction Watch 的撤稿数据，我们再用 OpenAlex 交叉核对一次；撤稿和撤回判“已撤稿”，期刊关注声明单独判“关注声明”，并给出声明的 DOI 和日期。示例里的 Wakefield 1998 会被判已撤稿。

展开：中文网页记录（知网、期刊官网）不标注撤稿，这类条目会注明“没有核对撤稿状态”。

H9 误报为什么降不下来?

短答：误报是长尾。每修一类（作者段格式、会议报告、软件、英文转写的中文期刊、数据库合并记录……），新数据里又冒出新的类型。真实世界的引文写法太多样，开放数据库的覆盖和元数据也有缺口。

展开：

- 这和 Badalova、Mayr 2026 年对 5 个同类工具的评测结论一致：引文解析错误、元数据不全、数据库覆盖有限都会拖累效果（arXiv:2607.22693）。
- 我们的应对是不硬判：拿不准的放“待人工 / 相近候选”，并保留核查过程让人复核。

H10 怎么保证“已核实”是对的?

短答：“已核实”要求题名、作者、年份、期刊、DOI 都和数据库一致；中文网页记录还要求卷、期、起始页至少一项对上。对照实验里 19 条全对，场景测试修复后 18 条全对。

展开：场景测试暴露过一次例外：知网 DOI 配错的真文献，修复前被判成已核实。改为读中国 DOI 注册机构的解析页核对之后，在同一批数据上复测，18 条已核实全对。这一点我们如实写在技术说明第 14 节。

H11 728 项测试测了什么?

短答：测试覆盖：

- 解析、比对、各数据源适配。
- 上游故障（超时、限流、错误页）、AI 协议校验。
- 接口、流式结果、报告。
- 文档导入与隐藏文字、Agent、论断核查、MCP、界面逻辑。

测试用固定的上游响应，不联网，所以能稳定复现；另有联网的评测脚本单独记录结果。

展开：

- 真实误报修好后都会补回归测试，例如 `real-world.test.ts` 逐条对应盲测里修过的条目。
- 每次提交前跑 lint、类型检查和生产构建。

I 中文文献

I1 知网没有接口，中文文献怎么核?

短答：标准体检会对 Crossref 确认不了的中文期刊论文自动联网核查：

1. 用 DeepSeek 的搜索接口（搜索引擎，不是大模型）按题名找知网、万方、维普的论文页。
2. 读手机知网文章页内嵌数据、期刊官网的 `citation_*` 元数据，补出作者、卷期。
3. 必要时按 ISSN、卷、页到 Crossref 定位。
4. 由规则逐字段判定，写明来源。

展开：

- 判定规则：
  - 已核实：题名、刊名、年份一致，作者对得上，并且卷号、期号或起始页至少一项对上。
  - 相近候选 + 原文链接：只差作者，或卷期页码核对不了。
  - 信息有误：题名、刊名、年份对上而作者对不上，正是“真题名配假作者”式的拼凑编造。
- 边界：
  - 只读公开页面，不登录、不绕过付费墙；转载站不当来源。
  - 每次请求最多 30 条、单条最多 25 秒；没配置密钥时整步跳过。
  - “AI 继续查”还可以让模型换写法再搜。

I2 中文核查效果如何？还有多少查不了?

短答：中文期刊论文的“待人工”从九成多降到约三成：

- 已看过的 122 条：91% 降到 32%。
- 新抽 40 条（规则定稿后只跑一次）：95% 降到 32.5%，已核实 15 条逐条复核全对。

两者的新口径误报都是 0。剩下约三分之一主要是搜索引擎没收录、物理类引文不写题名。

展开：

- 新样本 90 条中文参考文献整体的待人工从 95.6% 降到 67.8%，原因：
  - 学位论文、图书、报告、专利、标准、网页仍待人工（17 条）。
  - 29 条没有题名，其中 28 条是物理类“作者 年份 刊名 卷 页”的写法。
- 引文只写“卷: 页”时知网没有卷号，只能给相近候选。

I3 读知网、期刊官网的页面合规吗?

短答：只读公开页面，相当于用户自己打开网页：不登录、不带 cookie、不碰验证码页、不绕过付费墙，请求头如实写明是本工具；有的期刊官网会拒绝（HTTP 403），我们就跳过。每条最多读两个知网页面、两个期刊官网页面，并按站点限速、缓存 6 小时。

展开：读到的只是题名、作者、刊期这类书目信息，用来核对引文，不抓取或保存全文。

I4 知网的 DOI 是怎么核对的?

短答：知网登记的 DOI 在 doi.org 取不到元数据，大模型给文献配上同刊另一篇的 DOI，原来看不出来。10-23 开始读中国 DOI 注册机构的解析页，看这个 DOI 登记的题名和作者：登记的是另一篇，就按“DOI 指向别的文献”处理；登记的就是这一篇，只说明 DOI 属于它，年份、卷期页仍请人工核对。

展开：

- 这是场景测试发现的问题：1 条真文献配错知网 DOI 却被判成已核实，3 条编造只能交人工。修复后同一批复测，编造查出 10/11，已核实全对。
- 英文写法的中文文献不比对题名，避免中英题名对不上而误判。

I5 中英文混排、作者汉字和拼音怎么比?

短答：文本归一化时，英文按词切分，中文按相邻两字切分；作者比对支持汉字与拼音互相转换（比如“窦杰”对“Dou J”），用 pinyin-pro 处理多音字姓氏（曾 zeng、单 shan）。英文译名附中文原文的引文，按方括号里的中文原文去核对。

J 工程实现

J1 技术栈是什么？为什么选 Next.js?

短答：Next.js 16（App Router）+ React 19 + TypeScript 严格模式 + Tailwind CSS 4。选 Next.js 是因为页面和服务端接口在一个项目里，密钥只在服务端、前端只拿结果；核验引擎和界面完全分开，可以单独测试，也能被 MCP 复用。

J2 为什么结果是一条条出来的?

短答：参考文献核查要访问多个外部数据库，整份列表可能要十几秒到几十秒。我们用 NDJSON 流式返回，核完一条推一条，用户马上能看到结果；前端还会校验结果流是否完整，断流不会被当成“已完成”。

展开：服务端并发 3 条核验；用户可以随时停止，停止会中断模型请求和后续查询，报告会标明未完成。

J3 并发、限流和缓存怎么做的?

短答：外部请求统一走 `http.ts`：按主机限并发和间隔（比如 Crossref 无联系邮箱时 2 并发、间隔 300 毫秒），429 / 5xx 退避重试，结果内存缓存。中文搜索单独限流（同时 3 个、间隔 250 毫秒，低于 DeepSeek 搜索每秒 5 次的上限），页面结果缓存 6 小时。

J4 前端怎么保证性能?

短答：

- 中文字体自托管、按字符分片加载，只下载页面用到的字，改版后首页传输从约 2 MB 降到约 1 MB。
- 结果流式逐条渲染。
- 本地解析在前端实时显示“识别到 N 条”，不用等服务器。

J5 部署在哪里？怎么部署的？

短答：主要部署在魔搭创空间：Docker 镜像（Node 22、非 root 用户），免费 2 核 8 GB，国内能直接访问、不用登录；另有 Netlify 备用站。代码推到魔搭仓库后云端构建，构建前按清单筛选源码，并检查没有带上密钥。

展开：每次部署后用浏览器在公网实测桌面和手机，记录在 `eval/results/` 下，例如 10-23 公网复测 6 条结论全部符合、无障碍检查 0 处问题。

J6 代码规模和结构？哪个文件最核心？

短答：源码约 1.2 万行，测试约 6400 行。最核心的是 `src/lib/verify/verify.ts`（核验流程与结论）和 `match.ts`（逐字段比对、同一篇判定）；AI 部分在 `lib/ai`、`lib/agent`、`lib/claims`、`lib/vision`，MCP 在 `lib/mcp`。

展开：代码地图见答辩准备手册第 9 节。

J7 怎么保证代码质量？

短答：

- TypeScript 严格模式、ESLint；728 项自动测试；每次提交前跑测试、类型检查和生产构建。
- 依赖用 npm 官方漏洞库审计：10-23 发现 Next.js 16.4.0 的公开漏洞公告，已升级到 16.4.1。
- 每个真实误报修好后都补回归测试。

J8 外部数据源挂了怎么办？

短答：每个数据源都有超时、重试和错误分类；某个源失败时，那条结论标“未完成”并提示稍后重试，不当作“不存在”。OpenAlex 撤稿交叉核对失败时，会在结论后注明“撤稿状态交叉核验未完成”。

J9 请求超时、用户点停止会怎样？

短答：每个请求有总时限，快到时不再开始新的中文联网核查；用户点停止会立刻中断模型请求和后续查询。已经出来的结果保留，报告标明“未完成”，不会把半份结果当成完整报告。

K 前端与交互体验

K1 界面设计思路是什么？

短答：

- 单栏工作台，输入在上、结果在下；每条参考文献盖一个结论印章，一眼看出哪条有问题。
- 详情按需展开，展开就能看到字段比对和核查过程。
- 视觉上保留纸张和朱红印章的意象，对应“体检”和“盖章确认”。

K2 新手怎么上手?

短答:

- 第一次打开有约 2 秒的落印开场动画，接着是 6 步新手引导，最后一步一键载入示例并体检。
- 页眉“怎么用”随时重看。
- 输入框提示支持的格式，只贴 DOI 也行。

K3 无障碍和手机端做了吗?

短答：做了自动化走查：axe-core 在 7 个页面状态下 0 处违规，手机首屏能看到输入框和开始按钮，键盘从页首按 3 下 Tab 就到输入框；动效都遵循系统的“减少动画”设置。这是自动化检查，不是真人可用性研究，完整的无障碍评估还没做。

出处：`docs/competition/USABILITY-2026-10-18.md`、`eval/results/usability-2026-10-20-redesign/`。

K4 AI 交互体验体现在哪里?

短答：AI 每一步都可见：AI 继续查时，卡片上实时显示查了哪个库、用什么检索词、为什么这样查；论断核查给出原文引句并能定位到原文；AI 摘出的字段在比对表里单独标出。用户始终知道哪些是 AI 做的、依据是什么。

L 创新与同类工具

L1 项目最大的创新点是什么?

短答：把“引用可不可信”拆成可追溯的事实核验和证据核查，并坚持检索与裁决分离：大模型和搜索引擎只找候选、给依据，结论由规则给出，每个结论都能回到数据库记录或原文片段。在中文场景，我们打通了知网、万方、维普、期刊官网和中国 DOI 注册机构的证据链。

展开：创新定位是应用与工程组合，不声称新的基础模型或检索算法。技术创新 5 条、应用创新 4 条见答辩准备手册第 7 节。

L2 技术上有什么创新?

短答：五点：

1. 检索与裁决分离。
2. 中文证据链。
3. 论断 RAG 的混合检索加引句逐字校验和范围复核。
4. 导入时检测隐藏提示词，联网时防 SSRF。
5. 用 MCP 把核验能力开放给其他 AI。

L3 和已有的引用检查工具比有什么不同?

短答：国外已有同类工具，比如 CheckIfExist（查 Crossref、Semantic Scholar、OpenAlex）和 HalluCiteChecker。2026 年有研究评测了 5 个这类工具，结论是它们受引文解析错误、元数据不全和数据库覆盖不足拖累。我们没有和它们做过系统对照；我们的不同在于中文证据链、检索与裁决分离（拿不准不硬判）、论断级核查和规范写法生成。

展开：

- CheckIfExist：Abbonato，2026，arXiv:2602.15871。开源网页工具，按字符串相似度给匹配打分。
- HalluCiteChecker：Sakai、Kamigaito、Watanabe，2026，arXiv:2604.26835。可离线运行的轻量工具包。
- 评测：Badalova、Mayr，2026，arXiv:2607.22693，评测了 CheckIfExist、HalluCiteChecker、Hallucinator、HalRef、RefChecker。
- 我们也面对同样的长尾问题（见 H9），不能说“比它们都强”。

M 社会价值与商业

M1 社会价值是什么?

短答：AI 写作普及后，编造和写错的引用会污染学术记录，也让老师审稿更累。引用体检让学生在交稿前自查、让老师快速定位有问题的条目，并且每个结论都有依据，有助于学术诚信教育。

M2 商业模式和用户验证是什么?

短答：目前验证的是技术流程，没有付费用户、真实访谈或购买转化证据。设想的方向是高校图书馆、写作中心、投稿前检查的试点，按机构或按量收费；需要先观察每次核查耗时、误报复核成本和用户留存，这些都还没做。

M3 运行成本大概多少?

短答：标准体检主要用免费的公开数据库，规则核验不调用大模型，成本很低；中文期刊联网核查每条用 1–3 次搜索接口；AI 功能按 token 计费，Agent 每条约 5.5–5.8 千 token。完整的单位成本还没有核算，这是商业化前要补的。

M4 没有老师或真实用户的试用反馈，怎么说明它在真实场景里有用？

短答：老师的试用记录还没有收回，我们先做了开发方场景测试，并明确它不是用户研究：让 DeepSeek 按三个题目写 36 条参考文献，运行前逐条查证（11 条编造、22 条写对、3 条写错）。测试时的版本没有把编造的说成真实、写对的 22 条零误报；修复一个知网 DOI 问题后，同一批复测编造查出 10/11。

展开：

- 测试时的版本：编造的查出 7 条、其余交人工，但 1 条真文献配错知网 DOI 被判成已核实。
- 修复：改为读中国 DOI 注册机构的解析页核对。
- 同一批复测（看过结果再修，不是盲测）：编造查出 10 条、1 条交人工；已核实 18 条全对；仍有 1 条真论文被写成另一本期刊、联网又没搜到原文，被判“疑似编造”。
- 只贴 DOI：随机 30 篇，8 项字段 30/30 与 Crossref 一致。
- 样本小、开发方查证、没有第二人独立标注，只能说明这两种用法走得通。

出处：技术说明第 14 节；`eval/scenario-2026-10-23/truth.json`（每条附查证链接）。

N 局限与下一步

N1 最大的局限和下一步是什么？

短答：

- 外部数据库覆盖不完整：知网、万方没有开放接口，图书、学位论文、网页多判待人工。
- 真实论文盲测误报在 5%–18% 之间波动，是长尾。
- 开放全文只覆盖 Europe PMC 和 arXiv，模型判断关系也会有偏差。

下一步：按刊名、卷、页定位不写题名的中文引文；请第二人独立标注、扩大样本；请老师试用并记录用时；做长文档检索消融。

展开：

- 中文仍是短板但已缩小：新抽 40 条中文期刊论文待人工从 95% 降到 32.5%。
- 引文只写“卷: 页”时只能给相近候选；中文图书、学位论文仍待人工。

N2 哪些文献查不了？

短答：图书、学位论文、网页、标准、专利、法律文件、机构报告、没有 DOI 的会议和工作论文，开放数据库基本不覆盖，多判“待人工”。中文里还有不写题名的物理类引文、搜索引擎没收录的文章。网页类引文下一步打算打开网址核对标题。

N3 评委现场给一条我们查错的引文，怎么办?

短答：先承认结果，再展开核查过程看是哪一步出的问题：解析错、数据库缺记录，还是比对规则不对。这类问题正是我们一直在修的长尾。我们的设计保证了大多数情况下会落到“待人工 / 相近候选”，而不是把真的说成假的、假的说成真的。

O 团队与开发过程

O1 代码历史和团队信息为什么不完整?

短答：按真实状态说明：团队、学校和分工信息由队长补充，不事后制造历史或编造角色；本地功能和材料完成，不代表已经正式报名提交。代码仓库公开，保留了完整的提交历史。

O2 开发中有没有用 AI 编程？怎么证明你们懂代码?

短答：请队长按真实情况统一口径后如实回答，不要编造分工或开发经历。比赛要求选手能讲清所有代码，所以无论怎么回答，每一块代码都要有人能现场讲清调用链和关键函数（见答辩准备手册第 9 节的模块认领）。

展开：提交历史和 `PROJECT_STATE.md` 记录了每次改动的原因、评测和修复过程，可以作为开发过程的证据。

O3 开发中遇到的最大困难是什么?

短答（任选一个讲）：

- **误报的长尾**：每修一类，新数据又冒出新类型，所以我们坚持每轮修完另抽新数据盲测，不在看过的数据上自我感觉良好。
- **中文覆盖**：没有开放接口，最后用搜索接口加公开页面加 Crossref 定位拼出证据链，待人工从九成多降到三成。
- **模型判断的系统性偏差**：只读摘要时拿“总体”否定“子类”，用范围复核把这类错判从 38 次降到 0。

P 现场演示

P1 网络不好、魔搭打不开怎么办?

短答：提前 10 分钟打开魔搭；打不开就切本机（`pnpm dev`）或录屏视频，并说明魔搭是免费演示环境。不要硬等超过一分钟。

P2 演示结果和视频、文档里不一样怎么办?

短答：如实说明“外部数据库的返回会变化”，展开核查过程看每一步；不要临时找理由，也不要说“平时不是这样”。我们的数字都注明了运行日期和版本。

P3 评委让现场换一条引文试试?

短答：直接贴进去跑。结论是“待人工 / 相近候选”时，解释查不到不等于编造，并可以点“AI 继续查”；结论出乎意料时，展开核查过程讲清原因（见 N3）。

附：原题号对照

2026-10-26 前的答辩问答按 1–26 编号，项目记录里引用的旧题号对应如下。

原题号	现编号	原题号	现编号
1	B1	14	N1
2	B2	15	O1
3	C1、F1	16	G2
4	D2	17	C3
5	D4	18	H5
6	B6	19	H6
7	E1	20	B5
8	H4	21	I1
9	G1	22	A6
10	G3	23	A8
11	M2	24	D5
12	G6	25	A7
13	A5	26	M4